Universidade Federal de Juiz de Fora
Programa de Pós-graduação em Modelagem Computacional · Álgebra Linear Computacional · 2026.3

Métodos diretos e comparação com a LAPACK

Augusto De Filippo Cavalini · Prof. José J. Camata

1. Matrizes escolhidas

As três matrizes vêm da coleção Harwell-Boeing, obtida no repositório Matrix Market do NIST, porque os downloads da SuiteSparse devolviam erro de acesso na época dos testes. A **bcsstk15** é a matriz de rigidez do módulo de uma plataforma offshore (análise estática estrutural). É a maior das três e representa o caso (a), SPD. A **steam2** vem de um modelo 3D de injeção de vapor em reservatório de petróleo (grade 5×5×6 com 4 graus de liberdade por célula). É não simétrica e cobre o caso (b). Também cobre o caso (c), pois o RCM reduz a sua banda de 331 para 76. A **1138_bus** é a matriz de admitância de uma rede elétrica de 1138 barras, SPD. Ela dá um segundo exemplo do caso (c), agora resolvido com Cholesky. Todas têm $500 \le m \le 5000$, e as origens diferentes dão padrões de esparsidade e condicionamentos variados.

2. Máquina e metodologia

Máquina: AMD Ryzen 5 5600 (6 núcleos; caches L1d de 32 KiB e L2 de 512 KiB por núcleo, L3 de 32 MiB compartilhada), 15 GiB de memória, Ubuntu 26.04. **Software:** g++ 15.2.0 com `-O2 -march=native -std=c++17`, OpenBLAS 0.3.32, LAPACKE 3.12.1 e Boost 1.90. **Medição:** `OPENBLAS_NUM_THREADS=1`; `std::chrono::steady_clock`; mediana de 5 execuções, alternando a versão implementada e a da LAPACK a cada repetição; cópias de A fora do cronômetro. Em todos os testes, $x = (1, \ldots, 1)^T$ e $b = Ax$. A verificação de NaN do LAPACKE foi desligada (`LAPACKE_set_nancheck(0)`), porque ela percorre os dados antes de cada chamada e não faz parte das rotinas da LAPACK. Como os erros são medidos na norma infinito, o limite do erro usa $\kappa_\infty(A)$, estimado com `dlange` + `dgetrf` + `dgecon`; $u = 1{,}1 \times 10^{-16}$.

Resíduo e erro. O **resíduo** usado em todo o relatório é o resíduo relativo $\|b - A\hat{x}\|_\infty / (\|A\|_\infty \|\hat{x}\|_\infty)$. Por um resultado de Rigal e Gaches, ele é exatamente a menor perturbação relativa de A para a qual a solução calculada $\hat{x}$ seria a solução exata (o *backward error*). Um resíduo próximo de u significa que o método resolveu exatamente um sistema muito próximo do original, isto é, que ele é estável. O **erro** é $\|\hat{x} - x\|_\infty / \|x\|_\infty$, a distância até a solução verdadeira. Ele depende também do condicionamento: em primeira ordem, erro $\le \kappa(A) \times$ resíduo.

3. Implementações

Armazenamento denso: um único vetor em ordem coluna-maior, $a(i, j) = a[i + j \cdot m]$, o formato que a LAPACK espera. **Banda:** o arranjo da LAPACK, com $(b_I + b_S + 1) \cdot m$ posições, em que $a(i, j)$ fica na linha $b_S + i - j$ da coluna j. No Cholesky em banda, $b_S = 0$ e só o triângulo inferior é guardado, em $(b + 1) \cdot m$ posições, como no `dpbtrf`. **Thomas:** três vetores (inferior, diagonal, superior). Todas as fatorações sobrescrevem a matriz recebida e ficam separadas das substituições.

Decisões: (i) a LU e o Cholesky usam a forma right-looking, com o laço mais interno ao longo das colunas, a ordem da memória. Em uma medição pontual com $m = 2000$, fora dos scripts deste relatório, a troca da ordem por linhas pela ordem por colunas reduziu a LU de 6,8 s para 1,2 s, sem mudar nenhum coeficiente. (ii) O vetor de pivôs usa a convenção da LAPACK, a partir de 1. (iii) O teste de pivô do Cholesky é $!(a_{kk} > 0)$, que também rejeita NaN. (iv) A LU em banda e o Thomas param em pivô nulo, mas não têm defesa contra pivôs pequenos; o

resíduo é o que revela esse caso.

Tabela 1. Validação em uma matriz pequena (tridiagonal SPD, m = 10), que todos os métodos conseguem resolver.

Método	Situação	Resíduo	Erro	Diferença para a solução da LAPACK
LU densa	OK	$4{,}9\times10^{-17}$	$1{,}1\times10^{-16}$	$2{,}2\times10^{-16}$
Cholesky densa	OK	$2{,}0\times10^{-16}$	$2{,}2\times10^{-16}$	$4{,}4\times10^{-16}$
LU em banda	OK	$4{,}9\times10^{-17}$	$1{,}1\times10^{-16}$	$2{,}2\times10^{-16}$
Cholesky em banda	OK	$2{,}0\times10^{-16}$	$2{,}2\times10^{-16}$	$2{,}2\times10^{-16}$
Thomas	OK	$4{,}9\times10^{-17}$	$1{,}1\times10^{-16}$	$2{,}2\times10^{-16}$

4. Parte 1: caracterização

Tabela 2. Caracterização das matrizes.

Matriz	m	nnz	nnz/m²	Simétrica	SPD	b_I	b_S	$\|A\|_1$	κ_1 estimado	Rotina
bcsstk15	3.948	117.816	$7{,}56\times10^{-3}$	sim	sim	437	437	$7{,}97\times10^{9}$	$7{,}97\times10^{9}$	dpocon
steam2	600	5.660	$1{,}57\times10^{-2}$	não	não	330	331	$4{,}69\times10^{9}$	$3{,}55\times10^{6}$	dgecon
1138_bus	1.138	4.054	$3{,}13\times10^{-3}$	sim	sim	1030	1030	$4{,}04\times10^{4}$	$1{,}23\times10^{7}$	dpocon

O arquivo da steam2 tem 13.760 entradas, mas 8.100 são zeros guardados explicitamente; por isso nnz = 5.660. As bandas e o grafo do RCM consideram só os valores realmente não nulos, como pede o enunciado. A página do NIST informa banda 438 para a bcsstk15 porque conta a diagonal; aqui b = 437 não a conta. Os valores de κ são da mesma ordem dos informados pelas fontes: $8{,}0\times10^{9}$ contra $6{,}5\times10^{9}$ na bcsstk15, $1{,}2\times10^{7}$ contra $8{,}6\times10^{6}$ na 1138_bus e $3{,}5\times10^{6}$ contra $3{,}5\times10^{6}$ na steam2.

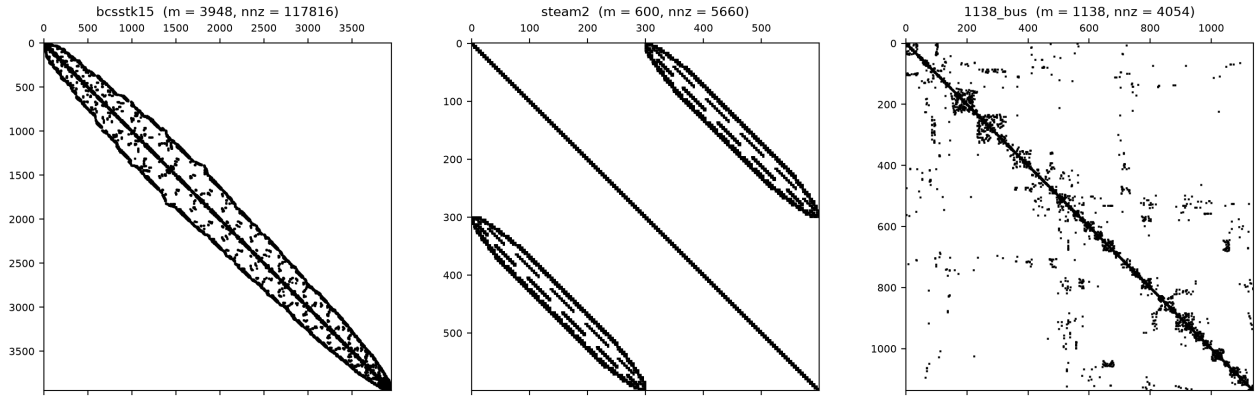


Figura 1. Padrões de esparsidade na ordem original.

5. Parte 3: reordenamento RCM e fatoração em banda

A permutação vem de `boost::cuthill_mckee_ordering`, com iterador reverso, sobre o grafo não direcionado de A. Com ela, formei $\tilde{A} = PAP^{T}$ e resolvi $\tilde{A}(Px) = Pb$. O programa confere que $\|\tilde{A}(Px) - Pb\|$ é da ordem de 10^{-16} em termos relativos e que o nnz não muda. O caso (c) do enunciado é a steam2; a 1138_bus é um segundo exemplo; a bcsstk15 entra como contraste.

Tabela 3. Larguras de banda e armazenamento, em número de posições, antes e depois do RCM.

Matriz	Ordem	b_I	b_S	LU em banda: $(b_I+b_S+1)m$	Cholesky em banda: $(b+1)m$	Densa: m^2
steam2	original	330	331	397.200	não simétrica	360.000
steam2	RCM	76	76	91.800	não simétrica	360.000
1138_bus	original	1030	1030	2.345.418	1.173.278	1.295.044
1138_bus	RCM	131	131	299.294	150.216	1.295.044
bcsstk15	original	437	437	3.454.500	1.729.224	15.586.704
bcsstk15	RCM	501	501	3.959.844	1.981.896	15.586.704

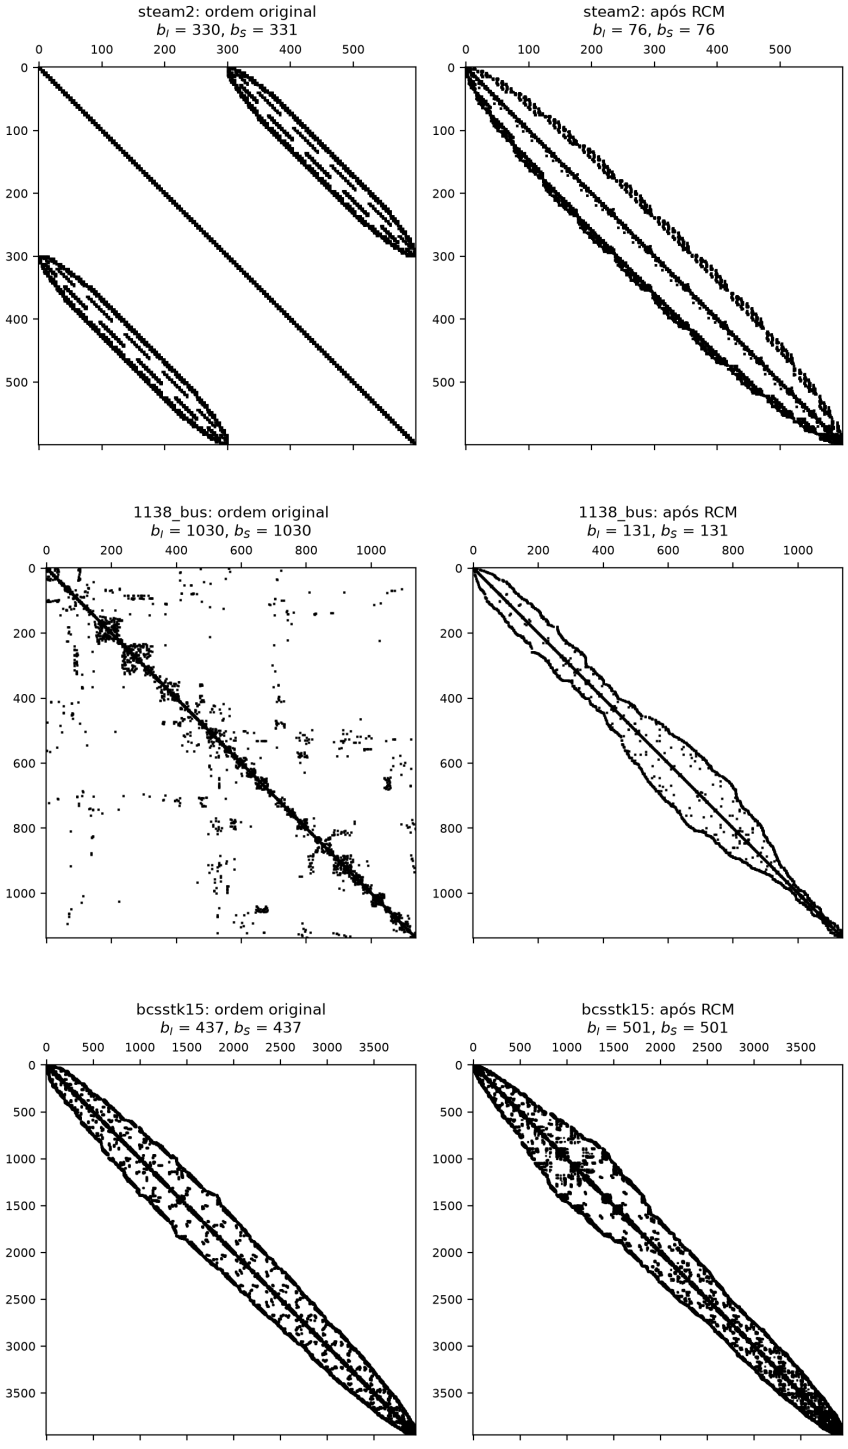


Figura 2. Padrões antes e depois do RCM. Na steam2 (caso c) e na 1138_bus, a banda cai bastante; na bcsstk15, ela aumenta.

Para cada matriz, resolvi Ax = b com LU, que vale para todas, e com Cholesky, que vale para as duas SPD. Cada método foi executado nas formas densa e em banda e nas duas ordens: **sem RCM**, com a matriz A na numeração original, e **com RCM**, com $\tilde{A} = PAP^T$. **Densa** é a fatoração com a matriz guardada inteira, em m^2 posições, que percorre toda a submatriz restante em cada etapa. **Em banda** é a mesma fatoração com o armazenamento da Seção 3, que só percorre a faixa entre b_I e b_S. Na LU, a densa usa pivoteamento parcial e a em banda não. Todas as fatorações das Tabelas 4 a 6 são as implementadas neste trabalho; a LAPACK só aparece na Parte 4. Os erros são sempre medidos no sistema original Ax = b: na ordem com RCM, x é recuperado de Px antes do cálculo.

Tabela 4. Tempos de fatoração e de solução, em segundos (mediana de 5 execuções).

Matriz	Método	Ordem	b_I	b_S	Fatoração densa (s)	Fatoração em banda (s)	Solução densa (s)	Solução em banda (s)
steam2	LU	sem RCM	330	331	$2{,}88\times10^{-2}$	$1{,}71\times10^{-2}$	$2{,}13\times10^{-4}$	$1{,}31\times10^{-4}$
steam2	LU	com RCM	76	76	$2{,}79\times10^{-2}$	$1{,}29\times10^{-3}$	$1{,}44\times10^{-4}$	$3{,}92\times10^{-5}$
1138_bus	LU	sem RCM	1030	1030	$1{,}93\times10^{-1}$	$1{,}93\times10^{-1}$	$7{,}63\times10^{-4}$	$1{,}11\times10^{-3}$
1138_bus	LU	com RCM	131	131	$1{,}91\times10^{-1}$	$7{,}43\times10^{-3}$	$9{,}30\times10^{-4}$	$1{,}54\times10^{-4}$
1138_bus	Cholesky	sem RCM	1030	1030	$1{,}04\times10^{-1}$	$9{,}99\times10^{-2}$	$1{,}06\times10^{-3}$	$8{,}84\times10^{-4}$
1138_bus	Cholesky	com RCM	131	131	$9{,}83\times10^{-2}$	$3{,}43\times10^{-3}$	$8{,}04\times10^{-4}$	$1{,}66\times10^{-4}$
bcsstk15	LU	sem RCM	437	437	$1{,}36\times10^{1}$	$2{,}85\times10^{-1}$	$9{,}59\times10^{-3}$	$2{,}81\times10^{-3}$
bcsstk15	LU	com RCM	501	501	$1{,}27\times10^{1}$	$3{,}67\times10^{-1}$	$9{,}75\times10^{-3}$	$2{,}92\times10^{-3}$
bcsstk15	Cholesky	sem RCM	437	437	$6{,}06\times10^{0}$	$1{,}46\times10^{-1}$	$1{,}09\times10^{-2}$	$1{,}86\times10^{-3}$
bcsstk15	Cholesky	com RCM	501	501	$6{,}01\times10^{0}$	$1{,}89\times10^{-1}$	$1{,}10\times10^{-2}$	$2{,}16\times10^{-3}$

Tabela 5. Ganho da fatoração em banda sobre a densa (quantas vezes ela é mais rápida) e taxas das duas formas. O ganho medido é a razão entre os tempos; o previsto é a razão entre as contagens de operações da fórmula do enunciado: $(2/3)m^3 \div 2m\cdot b_I\cdot b_S$ na LU e $(1/3)m^3 \div m\cdot b^2$ no Cholesky. As taxas em GFLOP/s dividem pelo tempo a contagem exata das operações que os laços executam.

Matriz	Método	Ordem	Ganho medido	Ganho previsto	GFLOP/s densa	GFLOP/s em banda
steam2	LU	sem RCM	1,68	1,10	5,00	4,86
steam2	LU	com RCM	21,63	20,78	5,15	4,94
1138_bus	LU	sem RCM	1,00	0,41	5,09	4,96
1138_bus	LU	com RCM	25,66	25,15	5,15	4,87
1138_bus	Cholesky	sem RCM	1,04	0,41	4,75	4,80
1138_bus	Cholesky	com RCM	28,63	25,15	5,00	5,33
bcsstk15	LU	sem RCM	47,70	27,21	3,02	4,91
bcsstk15	LU	com RCM	34,53	20,70	3,23	4,94
bcsstk15	Cholesky	sem RCM	41,65	27,21	3,38	4,82
bcsstk15	Cholesky	com RCM	31,86	20,70	3,42	4,83

Tabela 6. Erros no sistema original Ax = b (definições na Seção 2).

Matriz	Método	Ordem	Resíduo: densa	Resíduo: em banda	Erro: densa	Erro: em banda
steam2	LU	sem RCM	$8{,}1\times10^{-16}$	$8{,}1\times10^{-16}$	$1{,}4\times10^{-12}$	$9{,}9\times10^{-13}$
steam2	LU	com RCM	$8{,}1\times10^{-16}$	$1{,}0\times10^{-15}$	$1{,}8\times10^{-12}$	$1{,}9\times10^{-12}$
1138_bus	LU	sem RCM	$5{,}1\times10^{-16}$	$5{,}3\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}5\times10^{-11}$
1138_bus	LU	com RCM	$1{,}3\times10^{-16}$	$1{,}3\times10^{-16}$	$1{,}2\times10^{-12}$	$1{,}2\times10^{-12}$
1138_bus	Cholesky	sem RCM	$6{,}2\times10^{-16}$	$6{,}2\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}5\times10^{-11}$
1138_bus	Cholesky	com RCM	$2{,}0\times10^{-16}$	$2{,}0\times10^{-16}$	$1{,}5\times10^{-12}$	$1{,}5\times10^{-12}$
bcsstk15	LU	sem RCM	$1{,}7\times10^{-15}$	$1{,}1\times10^{-15}$	$8{,}4\times10^{-11}$	$8{,}1\times10^{-12}$
bcsstk15	LU	com RCM	$1{,}3\times10^{-15}$	$1{,}5\times10^{-15}$	$2{,}0\times10^{-10}$	$3{,}9\times10^{-12}$
bcsstk15	Cholesky	sem RCM	$9{,}6\times10^{-16}$	$9{,}6\times10^{-16}$	$8{,}2\times10^{-12}$	$8{,}2\times10^{-12}$
bcsstk15	Cholesky	com RCM	$1{,}4\times10^{-15}$	$1{,}4\times10^{-15}$	$5{,}1\times10^{-12}$	$5{,}1\times10^{-12}$

Efeito do RCM. Na steam2, a banda em ordem original já ajuda pouco (ganho de 1,68); com RCM, o ganho sobe para 21,6. Na 1138_bus, sem RCM a banda ocupa quase toda a matriz (b/m = 0,91) e a forma em banda leva o mesmo tempo da densa (ganho de 1,00 na LU e 1,04 no Cholesky); com RCM, ele vai a 25,7 e 28,6. Na bcsstk15, a numeração original já tem banda estreita, e o RCM a piora: o ganho cai de 47,7 para 34,5 na LU e de 41,6 para 31,9 no Cholesky. A forma densa leva praticamente o mesmo tempo nas duas ordens, porque percorre a matriz inteira de qualquer forma. Nas matrizes SPD, o Cholesky em banda é cerca de duas vezes mais rápido que a LU em banda, como prevê a razão $2m{\cdot}b^2 \div m{\cdot}b^2 = 2$ ($7{,}43\times10^{-3}$ s contra $3{,}43\times10^{-3}$ s na 1138_bus com RCM).

Medido e previsto. A fórmula do enunciado só vale para b muito menor que m. Quando b se aproxima de m, ela erra bastante: na 1138_bus sem RCM, prevê 0,41 (a banda seria mais lenta), mas o ganho medido é 1,00, porque os laços em banda nunca passam do tamanho da matriz. A contagem exata corrige isso e acompanha o ganho medido em até cerca de 10% na steam2 e na 1138_bus, onde as duas formas têm a mesma taxa, perto de 5 GFLOP/s. Na bcsstk15, o ganho medido supera até a contagem exata: a forma densa ocupa 125 MB, bem mais que os 32 MB da L3, e sua taxa cai para 3,38 GFLOP/s, enquanto a em banda, com cerca de 14 MB, mantém 4,82. A diferença de taxas explica o resto: $29{,}3 \times 4{,}82 \div 3{,}38 \approx 41{,}6$, perto do ganho medido de 41,6.

Precisão. As formas densa e em banda têm resíduos da mesma ordem, entre 10^{-16} e 10^{-15}, em todos os casos, inclusive nas LU em banda, que não pivotam, e o RCM não altera esse patamar. O erro varia um pouco mais entre as versões, por exemplo de $8{,}4\times10^{-11}$ sem RCM para $2{,}0\times10^{-10}$ com RCM na LU densa da bcsstk15, mas fica sempre abaixo de $\kappa_\infty u$ ($8{,}8\times10^{-7}$ nessa matriz). O RCM custou $4{,}9\times10^{-4}$ s na steam2, $1{,}0\times10^{-3}$ s na 1138_bus e $2{,}5\times10^{-2}$ s na bcsstk15, incluindo a montagem do grafo a partir da forma densa.

6. Parte 4: comparação com a LAPACK

Tabela 7. Resultados por matriz e por método, na ordem original das matrizes. Nas linhas de LU, ρ = max|u_{ij}| / max|a_{ij}|.

Matriz	Método	Implementação	Fatoração (s)	Solução (s)	GFLOP/s	Razão (÷ LAPACK)	Resíduo	Erro	$\kappa_\infty u$	ρ
1138_bus	LU densa	implementado	$1{,}80\times10^{-1}$	$5{,}33\times10^{-4}$	5,47	10,22	$5{,}1\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}4\times10^{-9}$	0,99
1138_bus	LU densa	LAPACK	$1{,}76\times10^{-2}$	$2{,}02\times10^{-4}$	55,88	-	$1{,}9\times10^{-16}$	$1{,}1\times10^{-11}$	$1{,}4\times10^{-9}$	0,99
1138_bus	LU em banda	implementado	$1{,}79\times10^{-1}$	$6{,}57\times10^{-4}$	13,47	9,34	$5{,}3\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}4\times10^{-9}$	0,99
1138_bus	LU em banda	LAPACK	$1{,}92\times10^{-2}$	$2{,}31\times10^{-4}$	125,73	-	$1{,}9\times10^{-16}$	$1{,}8\times10^{-12}$	$1{,}4\times10^{-9}$	0,99
1138_bus	Cholesky densa	implementado	$9{,}51\times10^{-2}$	$7{,}02\times10^{-4}$	5,16	10,80	$6{,}2\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}4\times10^{-9}$	-
1138_bus	Cholesky densa	LAPACK	$8{,}80\times10^{-3}$	$5{,}00\times10^{-4}$	55,79	-	$1{,}4\times10^{-16}$	$8{,}9\times10^{-12}$	$1{,}4\times10^{-9}$	-
1138_bus	Cholesky em banda	implementado	$9{,}24\times10^{-2}$	$6{,}88\times10^{-4}$	13,07	10,07	$6{,}2\times10^{-16}$	$1{,}5\times10^{-11}$	$1{,}4\times10^{-9}$	-
1138_bus	Cholesky em banda	LAPACK	$9{,}17\times10^{-3}$	$1{,}87\times10^{-4}$	131,62	-	$1{,}0\times10^{-16}$	$2{,}4\times10^{-12}$	$1{,}4\times10^{-9}$	-
bcsstk15	LU densa	implementado	$1{,}22\times10^{1}$	$9{,}22\times10^{-3}$	3,37	18,46	$1{,}7\times10^{-15}$	$8{,}4\times10^{-11}$	$8{,}8\times10^{-7}$	1,00
bcsstk15	LU densa	LAPACK	$6{,}60\times10^{-1}$	$4{,}96\times10^{-3}$	62,14	-	$6{,}7\times10^{-16}$	$3{,}6\times10^{-11}$	$8{,}8\times10^{-7}$	1,00
bcsstk15	LU em banda	implementado	$2{,}69\times10^{-1}$	$2{,}13\times10^{-3}$	5,61	5,13	$1{,}1\times10^{-15}$	$8{,}1\times10^{-12}$	$8{,}8\times10^{-7}$	0,70
bcsstk15	LU em banda	LAPACK	$5{,}23\times10^{-2}$	$1{,}82\times10^{-3}$	28,81	-	$1{,}7\times10^{-15}$	$1{,}4\times10^{-10}$	$8{,}8\times10^{-7}$	1,00
bcsstk15	Cholesky densa	implementado	$5{,}75\times10^{0}$	$1{,}07\times10^{-2}$	3,56	17,53	$9{,}6\times10^{-16}$	$8{,}2\times10^{-12}$	$8{,}8\times10^{-7}$	-
bcsstk15	Cholesky densa	LAPACK	$3{,}28\times10^{-1}$	$8{,}98\times10^{-3}$	62,48	-	$4{,}8\times10^{-16}$	$2{,}8\times10^{-12}$	$8{,}8\times10^{-7}$	-
bcsstk15	Cholesky em banda	implementado	$1{,}37\times10^{-1}$	$1{,}75\times10^{-3}$	5,49	8,86	$9{,}6\times10^{-16}$	$8{,}2\times10^{-12}$	$8{,}8\times10^{-7}$	-
bcsstk15	Cholesky em banda	LAPACK	$1{,}55\times10^{-2}$	$4{,}63\times10^{-4}$	48,62	-	$5{,}1\times10^{-16}$	$4{,}9\times10^{-12}$	$8{,}8\times10^{-7}$	-
steam2	LU densa	implementado	$2{,}69\times10^{-2}$	$1{,}40\times10^{-4}$	5,35	9,23	$8{,}1\times10^{-16}$	$1{,}4\times10^{-12}$	$5{,}4\times10^{-10}$	1,00
steam2	LU densa	LAPACK	$2{,}92\times10^{-3}$	$5{,}66\times10^{-5}$	49,38	-	$8{,}1\times10^{-16}$	$8{,}4\times10^{-13}$	$5{,}4\times10^{-10}$	1,00
steam2	LU em banda	implementado	$1{,}62\times10^{-2}$	$1{,}15\times10^{-4}$	8,07	7,39	$8{,}1\times10^{-16}$	$9{,}9\times10^{-13}$	$5{,}4\times10^{-10}$	1,00
steam2	LU em banda	LAPACK	$2{,}20\times10^{-3}$	$6{,}92\times10^{-5}$	59,68	-	$8{,}1\times10^{-16}$	$1{,}3\times10^{-12}$	$5{,}4\times10^{-10}$	1,00

Na forma em banda com ordem original, a taxa em GFLOP/s precisa de cuidado quando b é próximo de m: na 1138_bus (b/m = 0,91), a fórmula $2m\cdot b_I\cdot b_S$ vale cerca de $1{,}6m^3$, bem acima do custo real, que não passa de $(2/3)m^3$. Por isso a taxa aparente é de 13,5 GFLOP/s na LU em banda implementada, embora o tempo seja o mesmo da densa, com 5,5 GFLOP/s. Além disso, a contagem da tabela não inclui o pivoteamento do `dgbtrf`. Sem pivoteamento, ρ pode diferir: na bcsstk15, foi 0,70 na LU em banda implementada e 1,00 no `dgbtrf`.

Estudo de escala

Tabela 8. Fatoração de matrizes densas aleatórias. A matriz da LU tem coeficientes uniformes em [−1, 1]; a do Cholesky é simétrica, com m somado à diagonal (SPD, $\kappa_\infty \approx 2{,}3$).

m	LU implementado (s)	dgetrf (s)	Razão	GFLOP/s implementado	GFLOP/s dgetrf	ρ	Cholesky implementado (s)	dpotrf (s)	Razão	GFLOP/s implementado	GFLOP/s dpotrf
250	$2{,}01\times10^{-3}$	$3{,}33\times10^{-4}$	6,0	5,19	31,29	16,4	$1{,}01\times10^{-3}$	$1{,}46\times10^{-4}$	6,9	5,17	35,71
500	$1{,}64\times10^{-2}$	$1{,}96\times10^{-3}$	8,4	5,09	42,60	39,6	$8{,}63\times10^{-3}$	$9{,}02\times10^{-4}$	9,6	4,83	46,21
1.000	$1{,}28\times10^{-1}$	$1{,}33\times10^{-2}$	9,6	5,23	50,01	49,0	$6{,}65\times10^{-2}$	$6{,}48\times10^{-3}$	10,3	5,02	51,41
2.000	$1{,}19\times10^{0}$	$1{,}05\times10^{-1}$	11,4	4,46	50,68	80,0	$5{,}36\times10^{-1}$	$4{,}76\times10^{-2}$	11,3	4,98	56,06
4.000	$1{,}50\times10^{1}$	$8{,}17\times10^{-1}$	18,4	2,84	52,21	115,4	$7{,}19\times10^{0}$	$3{,}92\times10^{-1}$	18,3	2,97	54,38

Tabela 9. tridiag(−1, 2, −1): Thomas (fatoração + solução) e `dgtsv`. A taxa usa a contagem de 8m operações.

m	Thomas (s)	dgtsv (s)	Razão	GFLOP/s Thomas	GFLOP/s dgtsv	Resíduo	Erro	$\kappa_\infty u$
1.000	$1{,}32\times10^{-5}$	$1{,}25\times10^{-5}$	1,06	0,60	0,64	$8{,}3\times10^{-17}$	$2{,}8\times10^{-13}$	$5{,}5\times10^{-11}$
10.000	$1{,}40\times10^{-4}$	$1{,}19\times10^{-4}$	1,18	0,57	0,67	$1{,}1\times10^{-16}$	$1{,}3\times10^{-11}$	$5{,}5\times10^{-9}$
100.000	$1{,}39\times10^{-3}$	$1{,}19\times10^{-3}$	1,16	0,58	0,67	$8{,}3\times10^{-17}$	$5{,}2\times10^{-10}$	$5{,}5\times10^{-7}$
1.000.000	$1{,}46\times10^{-2}$	$1{,}27\times10^{-2}$	1,15	0,55	0,63	$1{,}1\times10^{-16}$	$7{,}4\times10^{-7}$	$5{,}5\times10^{-5}$

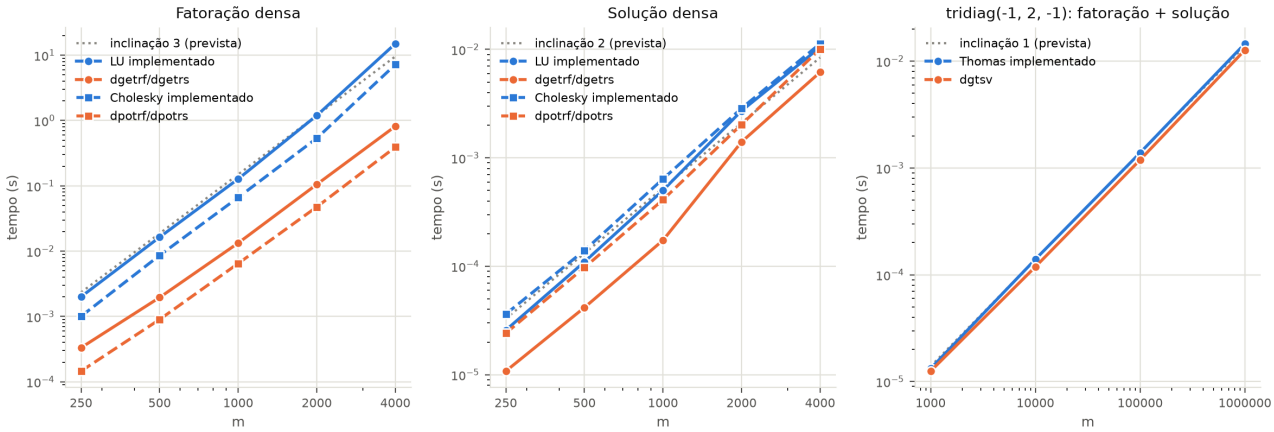


Figura 3. Tempos em escala log-log. A cor identifica a implementação; o traço e o marcador identificam o método. A reta pontilhada tem a inclinação prevista.

Tabela 10. Inclinações em log-log: reta ajustada a todos os pontos e inclinação entre os dois últimos pontos.

Rotina	Etapa	Prevista	Ajustada	Dois últimos pontos
LU implementado	fatoração	3	3,19	3,65
dgetrf/dgetrs	fatoração	3	2,83	2,96
Cholesky implementado	fatoração	3	3,16	3,75
dpotrf/dpotrs	fatoração	3	2,85	3,04
LU implementado	solução	2	2,20	1,95
dgetrf/dgetrs	solução	2	2,34	2,13
Cholesky implementado	solução	2	2,09	1,98
dpotrf/dpotrs	solução	2	2,18	2,31
Thomas implementado	fatoração + solução	1	1,01	1,02
dgtsv	fatoração + solução	1	1,00	1,03

As inclinações concordam com a teoria: cerca de 3 na fatoração densa, 2 na solução e 1 no Thomas. O desvio mais claro é o das fatorações densas implementadas entre m = 2000 e 4000 (3,65 na LU e 3,75 no Cholesky). A taxa cai de cerca de 5 para cerca de 3 GFLOP/s justamente quando a matriz passa de 32 MB, o tamanho da L3, para 128 MB, enquanto a LAPACK mantém a taxa (2,96 no `dgetrf`). Nas matrizes menores, a LAPACK tem inclinação ajustada abaixo de 3 porque sua taxa ainda está crescendo (31,3 GFLOP/s em m = 250 e 50,0 em m = 1000). Os tempos de solução são curtos e mais ruidosos, por isso as inclinações deles variam mais. Nas densas aleatórias, ρ cresce de 16,4 para 115,4, muito abaixo do pior caso 2^{m-1}.

7. Questões para discussão

1. Por que a LAPACK é mais rápida que a minha LU densa, se os dois códigos fazem o mesmo número de operações?

A contagem de operações não determina o tempo: o acesso à memória e o aproveitamento do processador pesam tanto quanto ela. Minha LU está de 6,0 a 18,5 vezes atrás, com cerca de 5 GFLOP/s ou menos, enquanto a LAPACK fica entre 50 e 62 GFLOP/s a partir de m = 1000. A minha aplica cada etapa k a toda a submatriz restante, passando pela matriz inteira m vezes; quando ela não cabe no cache, quase todo acesso custa uma ida à memória. A LAPACK com OpenBLAS organiza a conta em blocos que cabem no cache e usa núcleos BLAS nível 3 escritos para o processador, com vetorização e várias operações por ciclo. A queda da minha taxa acima de m = 2000, sem queda equivalente na LAPACK, é compatível com isso. Só medi separadamente o efeito da ordem dos laços; não isolei a contribuição dos blocos e a dos

núcleos otimizados.

2. A diferença de desempenho é a mesma para matrizes densas, em banda e tridiagonais?

Não. A razão entre os tempos é de 6,0 a 18,5 na LU densa e de 6,9 a 18,3 no Cholesky denso; cai para 5,1 a 9,3 na LU em banda e 8,9 a 10,1 no Cholesky em banda; e fica em 1,06 a 1,18 no Thomas. A vantagem da LAPACK vem de blocos e de operações sobre muitos dados, e esse espaço diminui com a banda. Nas faixas estreitas, os laços são curtos e os dados cabem no cache, então a minha taxa nem sofre: 5,5 GFLOP/s no Cholesky em banda da bcsstk15, contra 3,6 no denso. As maiores razões em banda aparecem na 1138_bus, com b/m = 0,91, que na prática é densa. No caso tridiagonal, cada etapa faz poucas contas sobre poucos valores, sem nada a agrupar em blocos: as duas rotinas ficam perto de 0,6 GFLOP/s, e o `dgtsv` leva uma vantagem pequena.

3. Os erros são compatíveis com κ(A)u? Em que matrizes o erro é grande mesmo com resíduo pequeno?

Sim. Nas 48 medições, a relação $\|\hat{x} - x\|/\|x\| \le \kappa_\infty \cdot$(resíduo) vale sempre, e todas as matrizes reais ficam também abaixo de $\kappa_\infty u$. A única exceção a $\kappa_\infty u$ é a SPD aleatória, com $\kappa_\infty \approx 2{,}3$: em m = 4000, o erro é $9{,}4\times10^{-15}$ contra $\kappa_\infty u = 2{,}5\times10^{-16}$. Isso não indica defeito: κu ignora as constantes que crescem com m, e com κ tão pequeno essas constantes aparecem. O erro é grande, apesar do resíduo pequeno, nas matrizes mal condicionadas: bcsstk15 (LU densa: resíduo $1{,}7\times10^{-15}$, erro $8{,}4\times10^{-11}$), 1138_bus ($5{,}1\times10^{-16}$ e $1{,}5\times10^{-11}$) e, principalmente, tridiag(−1, 2, −1) com $m = 10^6$ ($1{,}1\times10^{-16}$ e $7{,}4\times10^{-7}$). Nesses casos, os métodos são estáveis: o resíduo pequeno mostra que eles resolvem exatamente um sistema muito próximo, e o erro maior em x vem do condicionamento, não do algoritmo.

4. Quando vale a pena reordenar e usar a fatoração em banda em vez da densa?

A banda vale a pena quando b é bem menor que m; o reordenamento, quando reduz b. **Memória:** o armazenamento em banda só é menor que o denso se $b_I + b_S + 1 < m$. Na 1138_bus e na steam2 em ordem original, ele chega a ser maior (2.345.418 contra 1.295.044 posições na 1138_bus), e o RCM inverte isso (150.216 posições no Cholesky em banda). **Tempo:** com o RCM, a fatoração em banda ficou 22 vezes mais rápida que a densa na steam2 e 29 vezes na 1138_bus (Cholesky). Sem reordenar, a 1138_bus (b/m = 0,91) leva o mesmo tempo da densa. O RCM é barato em relação à fatoração densa: de $4{,}9\times10^{-4}$ a $2{,}5\times10^{-2}$ s nestes testes, mesmo montando o grafo a partir da forma densa. Em relação à fatoração em banda, ele não é desprezível: equivale a 38% dela na steam2 e 30% na 1138_bus. **Mas ele nem sempre ajuda:** na bcsstk15, a banda aumenta de 437 para 501, e o Cholesky em banda fica 1,30 vezes mais lento ($1{,}46\times10^{-1}$ s sem RCM, $1{,}89\times10^{-1}$ s com RCM), o que concorda com a razão das contagens exatas, 1,30. Como essa matriz já tem banda estreita na numeração original, o certo é medir b antes e depois e ficar com a menor. **Estabilidade:** a LU em banda não pivota, então é preciso conferir o resíduo; nas matrizes SPD, o Cholesky em banda não tem esse risco. Por fim, o custo da solução também cai com a banda, o que aumenta a vantagem quando há muitos lados direitos.

8. Conclusões

As implementações se mostraram corretas: o maior resíduo é $1{,}5\times10^{-14}$, no mesmo patamar da LAPACK. A LAPACK é de 6 a 18 vezes mais rápida na forma densa, mas a vantagem encolhe com a banda e quase desaparece no caso tridiagonal, o que mostra que contar operações não basta: a organização dos acessos à memória é decisiva, como mostra também a ordem dos laços. Por outro lado, escolher a estrutura certa pesa mais que a qualidade da implementação: meu Cholesky em banda fatora a bcsstk15 em $1{,}46\times10^{-1}$ s, bem menos que os $3{,}28\times10^{-1}$ s do `dpotrf` denso. O RCM costuma ser um passo barato e muito vantajoso, mas o resultado depende da matriz, como mostra a bcsstk15. O passo a passo para reproduzir cada tabela e figura está no README do código.